

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Российский университет дружбы народов имени Патриса Лумумбы»

Факультет физико-математических и естественных наук
Кафедра прикладной информатики и теории вероятностей

«Допустить к защите»
Заведующий кафедрой
прикладной информатики
и теории вероятностей
д.т.н., профессор
_____ К. Е. Самуйлов
«__» _____ 20__ г.

**Выпускная квалификационная работа
магистра**

Направление 01.04.02 «Прикладная математика и информатика»
Магистерская программа «Теория вероятностей и математическая
статистика»

ТЕМА

**«Анализ чувствительности ресурсных систем массового
обслуживания к распределению времени обслуживания и типу
входящего потока»**

Выполнил студент
(Фамилия, имя, отчество)

Лобов Михаил Сергеевич

Группа
Студ. билет №

НПМмд-02-24
1332249565

Руководитель выпускной квалифика-
ционной работы

Сопин Эдуард Сергеевич, кандидат
физико-математических наук, до-
цент, младший научный сотрудник

(Ф.И.О., степень, звание, должность)

Автор _____
(Подпись)

г. Москва
2026 г.

АННОТАЦИЯ

Объект исследования: ...

Предмет исследования: ...

Цель: ...

Задачи: ...

Ключевые слова: ...

АННОТАЦИЯ

В магистерской диссертации исследуется задача инвариантности стационарного распределения системы массового обслуживания с ограниченными ресурсами и интенсивностями поступления $\lambda(n)$ и обслуживания $\mu(n)$, зависящими от состояния системы. Рассматривается конечная стохастическая модель, в которой состояние определяется числом заявок в системе, а динамика задаётся механизмами поступления, обслуживания и отказа при достижении предельной ёмкости. Центральный вопрос состоит в установлении условий, при которых стационарное распределение $\pi(n)$ не зависит от формы закона обслуживания и определяется только его основными числовыми характеристиками, прежде всего математическим ожиданием.

В работе формализуются понятия строгой инвариантности и почти инвариантности стационарного режима. Получаются достаточные условия инвариантности на основе балансных соотношений, идей обратимости и квазиреверсивности. Наряду с этим исследуются режимы, в которых указанное свойство нарушается. Для количественного анализа отклонений стационарных распределений при различных законах обслуживания используются метрики total variation и Kullback--Leibler. Это позволяет перейти от бинарной схемы "инвариантность/неинвариантность" к более тонкому описанию областей слабой чувствительности модели к форме распределения времени обслуживания.

Теоретическая часть дополняется дискретно-событийным имитационным моделированием. Разрабатывается DES-симулятор для систем с конечной ёмкостью, state-dependent интенсивностями и несколькими классами распределений обслуживания при фиксированном среднем. В вычислительных экспериментах сопоставляются экспоненциальный, эрланговский, гиперэкспоненциальный и детерминированный законы обслуживания. Анализируются стационарные вероятности состояний, среднее число заявок в системе, вероятность отказа и связанные показатели качества обслуживания. Дополнительно исследуется влияние параметров K , формы функций $\lambda(n)$, $\mu(n)$ и вариативности времени обслуживания на характер стационарного режима.

Ожидаемые результаты включают получение достаточных условий инвариантности для выделенного класса систем, построение контрпримеров, в которых форма распределения обслуживания существенно влияет на стационарные характеристики, выделение зон почти-инвариантности и разработку вычислительного инструментария для их идентификации. Практическая значимость работы связана с возможностью обоснованного упрощения моделей систем связи и вычислительных систем с ограниченными ресурсами. В тех режимах, где инвариантность или почти инвариантность имеет место, допустимо использовать более простые экспоненциальные аппроксимации без существенной потери точности. В противоположных режимах форма распределения времени обслуживания должна учитываться явно, поскольку она влияет на вероятность отказа, загрузку системы и другие эксплуатационные характеристики.

Ключевые слова: стационарное распределение, инвариантность, insensitivity, система массового обслуживания, ограниченные ресурсы, ограниченная ёмкость, интенсивности, зависящие от состояния, $\lambda(n)$, $\mu(n)$, квазиреверсивность, имитационное моделирование.

ОГЛАВЛЕНИЕ

АННОТАЦИЯ	1
Аннотация	2
СПИСОК СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	6
ВВЕДЕНИЕ	10
0.1 Формальная постановка ресурсной СМО	10
0.2 Семейства распределений обслуживания и входного потока .	10
0.3 Алгоритм имитационного моделирования	10
0.4 Архитектура программного комплекса	10
0.5 Исследуемые метрики и показатели чувствительности	10
0.6 Верификация модели и проверка корректности реализации . .	10
Выводы по главе 2	10
1 Ресурсные системы массового обслуживания: обзор подходов и постановка задачи исследования	11
1.1 Инвариантность в теории очередей	11
1.2 Системы с ограниченными ресурсами	11
1.3 Интенсивности, зависящие от состояния	11
1.4 Состояние вопроса и постановка задачи	11
Выводы по главе 1	12
2 Математическая модель и методика имитационного исследования	13
2.1 Постановка ресурсной СМО	13
2.2 Исследуемые метрики и показатели чувствительности	14
2.3 Алгоритм имитационного моделирования	16
2.4 Семейства распределений обслуживания и входного потока .	24
2.5 Структура программного комплекса и стадии эксперимента .	28

2.6	Контроль корректности и статистической надёжности результатов	31
3	Вычислительный анализ чувствительности ресурсной системы	32
3.1	Параметры вычислительного эксперимента	32
3.2	Сценарии анализа чувствительности	33
3.2.1	Моделирование входящего потока (Arrival Process) . .	33
3.2.2	Моделирование времени обслуживания (Workload) . .	34
3.3	Чувствительность к распределению объёма работы заявки . .	35
3.4	Чувствительность к типу входящего потока	38
3.5	Совместное влияние распределения обслуживания и входного потока	43
3.6	Практическая интерпретация результатов и выводы	49
	ЗАКЛЮЧЕНИЕ	51
A	Таблицы параметров вычислительного эксперимента	52

СПИСОК СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

Сокращения

СМО ---	система массового обслуживания.
ИМ ---	имитационное моделирование.
СВ ---	случайная величина.
ФР ---	функция распределения.
ЛСТ ---	преобразование Лапласа--Стилтьеса.
ЦПТ ---	центральная предельная теорема.
ЦМ ---	цепь Маркова.
МП ---	марковский процесс.
МАР ---	<i>Markovian Arrival Process</i> , марковский поток событий.
MArP ---	альтернативное обозначение марковского потока событий, используемое для устранения неоднозначности термина МАР.
ВМАР ---	<i>Batch Markovian Arrival Process</i> , групповой марковский поток событий.
ММАР ---	<i>Marked Markovian Arrival Process</i> , маркированный марковский поток событий.
ММРР ---	<i>Markov Modulated Poisson Process</i> , марковски-модулированный пуассоновский поток.
РН ---	<i>Phase-Type distribution</i> , распределение фазового типа.
МЕ ---	<i>Matrix-Exponential distribution</i> , матрично-экспоненциальное распределение.

QBD ---	<i>Quasi-Birth-and-Death process</i> , квазипроцесс рождения и гибели.
PASTA ---	<i>Poisson Arrivals See Time Averages</i> .
TV ---	расстояние полной вариации (<i>total variation distance</i>).
KL ---	дивергенция Кульбака--Лейблера.

Основные обозначения

K ---	ёмкость системы по числу заявок в редуцированной одноресурсной или одноканальной постановке.
N ---	число обслуживающих приборов; максимальное число заявок, одновременно находящихся в обслуживании.
n, k ---	индекс состояния; число заявок в системе.
M ---	число типов ресурсов.
L ---	число типов заявок.
R_m ---	общий объём ресурса типа m .
R ---	совокупный объём доступного ресурса; в много-ресурсной постановке --- совокупность бюджетов ресурсов.
$r_j = (r_{j1}, \dots, r_{jM})$ ---	вектор требований j -й заявки к ресурсам.
$F(x)$ ---	функция распределения требований заявки к ресурсу.
$F_l(x)$ ---	функция распределения требований к ресурсам для заявок типа l .
$F^{(k)}(x)$ ---	k -кратная свёртка функции распределения $F(x)$.
$A_l(x)$ ---	функция распределения межприходных интервалов заявок типа l .

$B(x)$ ---	функция распределения объёма работы или времени обслуживания заявки.
$B_l(x)$ ---	функция распределения времени обслуживания заявок типа l .
$\tilde{B}(x)$ ---	распределение остаточного объёма работы.
b ---	средний объём работы заявки; среднее время обслуживания.
$\mu = 1/b$ ---	параметр экспоненциального распределения времени обслуживания в марковском частном случае.
$\lambda(n)$ ---	интенсивность поступления заявок в состоянии n .
λ_k ---	интенсивность поступления заявок в состоянии k .
$\mu(n)$ ---	интенсивность обслуживания в состоянии n в редуцированной модели.
σ_k ---	суммарная скорость обслуживания в состоянии k в ресурсной модели.
α_n ---	коэффициент изменения скорости обслуживания после поступления заявки в state-dependent $M/G/1$ -модели.
$\xi(t)$ ---	число заявок в системе в момент времени t .
$\gamma(t)$ ---	вектор или матрица занятых ресурсов в момент времени t .
$\delta(t)$ ---	вектор суммарно занятых ресурсов по всем типам.
$X(t)$ ---	случайный процесс, описывающий состояние системы.
$\pi(n)$ ---	стационарная вероятность состояния n .

p_0 ---	стационарная вероятность пустой системы.
$p_k(r_1, \dots, r_k)$ ---	стационарное распределение по числу заявок и занятым ими ресурсам.
$\mathbb{E}[N], \mathbb{E}[\xi]$ ---	среднее число заявок в системе.
$\mathbb{P}\{N = K\}$ ---	вероятность полной загрузки системы в редуцированной постановке.
P_{loss} ---	вероятность потери или блокировки заявки.
$P_{\text{serv-loss}}$ ---	вероятность отказа из-за отсутствия свободного прибора.
Λ_{eff} ---	эффективная пропускная способность системы.

ВВЕДЕНИЕ

В данной главе формулируется математическая модель исследуемой ресурсной системы массового обслуживания с интенсивностями, зависящими от состояния. Описываются выбранные семейства распределений времени обслуживания и входящего потока, а также вводится набор ключевых метрик для оценки чувствительности системы. Кроме того, детально рассматривается алгоритм имитационного моделирования, архитектура разработанного программного комплекса и методика верификации полученных результатов.

0.1 Формальная постановка ресурсной СМО

0.2 Семейства распределений обслуживания и входного потока

0.3 Алгоритм имитационного моделирования

0.4 Архитектура программного комплекса

0.5 Исследуемые метрики и показатели чувствительности

0.6 Верификация модели и проверка корректности реализации

Выводы по главе 2

В данной главе была формализована математическая модель... (краткий параграф-выжимка). Разработанный на базе языков Rust и Python программный комплекс позволяет проводить масштабные вычислительные эксперименты с высокой производительностью и гарантированной воспроизводимостью. Верификация на частных случаях подтвердила математическую корректность симулятора. Введенный аппарат метрик и дизайна эксперимента дает необходимую основу для проведения сравнительного анализа, результаты которого будут подробно рассмотрены в Главе 3.

1 РЕСУРСНЫЕ СИСТЕМЫ МАССОВОГО ОБСЛУЖИВАНИЯ: ОБЗОР ПОДХОДОВ И ПОСТАНОВКА ЗАДАЧИ ИССЛЕДОВАНИЯ

1.1 Инвариантность в теории очередей

1.2 Системы с ограниченными ресурсами

В данном разделе должна быть представлена постановка задачи для систем массового обслуживания, в которых заявка занимает не только прибор, но и некоторый объём одного или нескольких ограниченных ресурсов. Следует показать, что такие модели естественно возникают при анализе вычислительных и телекоммуникационных систем, где отказ определяется не только занятостью приборов, но и нехваткой ресурса. Кроме того, необходимо описать связь ресурсных систем с классическими loss-system и указать, какие результаты об инвариантности уже известны для этого класса моделей.

1.3 Интенсивности, зависящие от состояния

Этот раздел должен быть посвящён системам, в которых интенсивности поступления и обслуживания зависят от текущего состояния системы. Необходимо объяснить, что функции $\lambda(n)$ и $\mu(n)$ отражают не формальное усложнение модели, а реальные механизмы управления доступом, деградации скорости при росте нагрузки и адаптации обслуживания к текущему числу заявок. Следует также отметить, что переход к state-dependent режиму приводит к существенным аналитическим трудностям и требует отдельного анализа стационарных характеристик в непрерывном времени и в моменты поступления заявок.

1.4 Состояние вопроса и постановка задачи

В заключительном разделе первой главы необходимо синтезировать результаты обзора и сформулировать исследовательский зазор. Здесь следует показать, какие свойства инвариантности уже доказаны для систем с

ограниченными ресурсами, какие результаты получены для state-dependent моделей, и какие вопросы остаются открытыми в их пересечении. На этой основе должна быть дана постановка задачи диссертации, включая объект и предмет исследования, цель работы, основные задачи и краткое обоснование выбора методов исследования.

Выводы по главе 1

В первой главе формируется теоретическая рамка исследования инвариантности стационарного распределения в системах массового обслуживания с ограниченными ресурсами и интенсивностями, зависящими от состояния. Рассмотрение классических результатов об инвариантности, ресурсных моделей и state-dependent постановок позволяет выделить научный зазор, который определяет содержание последующих глав. Во второй главе на этой основе будет введена математическая модель и формализованы исследуемые характеристики и условия.

2 МАТЕМАТИЧЕСКАЯ МОДЕЛЬ И МЕТОДИКА ИМИТАЦИОННОГО ИССЛЕДОВАНИЯ

2.1 Постановка ресурсной СМО

В данном разделе будет смоделирована и рассмотрена ресурсная loss система массового обслуживания, где каждая поступающая заявка занимает 1 канал и случайный объем ограниченного ресурса, а скорость поступления заявок и время их обработки зависит постоянно только от характера их распределения.

Основные параметры модели:

Таблица 2.1: Основные параметры модели

Наименование параметра	Обозначение
Количество приборов	$N = \text{SERVERS_N}$
Число обслуживающих каналов	$K = N$
Вместимость системы по ресурсам	$Res = \text{TOTAL_RESOURCE_R}$
Средняя интенсивность поступления	λ
Скорость обслуживания	σ
Случайное требование заявки к ресурсу	D
Случайный объем работы заявки	B
Фактическое время работы заявки	$S = \frac{B}{\sigma}$

Состояние системы в агрегированном виде описываются через $n(t)$ и $u(t)$ - число заявок и занятый ресурс в момент времени t . Новая заявка при попадании в систему имеет $D \sim F_D$ и $B \sim F_B$. Заявка принимается, если одновременно выполнены ограничения:
$$\begin{cases} n(t) < N \\ u(t) + D \leq R \end{cases}$$

Так как система не имеет буфера, то заявка теряется, если не выполнено хотя бы одно ограничение. Заявка обслуживается $S = \frac{B}{\sigma}$, после чего

освобождает ресурс и канал.

В работе рассматривается ресурсную многоканальную loss-СМО с одним типом ограниченного ресурса, случайными ресурсными требованиями, общим распределением объема работы и варьируемым типом входящего потока $GI/G/N/N/R$. GI отвечает за тип входящего потока, G --- за распределение объема работы заявки, N --- за число обслуживающих приборов и за число заявок в системе, R --- за общий объем ресурса в системе.

Такая постановка задачи является общим случаем $M/G/N/N/R$ системы. Система не является марковской, потому что на вход подается не только экспоненциально распределенный поток заявок, ведь для предсказания будущего состояния необходимо знать остаточное время до следующего поступления. Формально систему можно сделать марковской, если расширить состояние, храня фазы поступлений и обслуживаний, однако это приведет к резкому росту размерности и компьютерная имитация становится слишком затратной.

Таким образом агрегированная модель $(n(t), u(t))$ не является марковской при общем входящем потоке и неэкспоненциальном workload. Отдельные частные случаи сочетаний распределений входящего потока и времени работы будут рассмотрены в 3й главе.

2.2 Исследуемые метрики и показатели чувствительности

Каждый сценарий имитационного эксперимента задаётся набором параметров

$$s = (a, \omega, \lambda, \sigma, N, R, F_D),$$

где a --- тип входящего потока, ω --- распределение объёма работы заявки, λ --- средняя интенсивность поступления, σ --- скорость обслуживания, N --- число обслуживающих каналов, R --- общий объём ресурса, F_D --- распределение ресурсного требования.

Результатом моделирования сценария s является набор функционалов системы $m = m(s)$. В работе анализируются следующие основные метрики: вероятность отказа, пропускная способность, среднее число заявок в системе, средний занятый ресурс, среднее время обслуживания и среднее время пребывания заявки в системе.

Вероятность отказа оценивается как доля потерянных заявок среди всех поступивших:

$$\hat{P}_{\text{loss}} = \frac{N_{\text{rej}}}{N_{\text{arr}}},$$

где N_{arr} --- число поступивших заявок, N_{rej} --- число заявок, отклонённых из-за нарушения ограничений по числу серверов или доступному ресурсу.

Пропускная способность системы определяется как среднее число успешно принятых и завершённых заявок в единицу времени наблюдения:

$$\hat{\theta} = \frac{N_{\text{acc}}}{T_{\text{obs}}},$$

где N_{acc} --- число принятых заявок, $T_{\text{obs}} = T_{\text{max}} - T_{\text{warm}}$ --- длина интервала, на котором собирается статистика.

Среднее число заявок в системе оценивается как временное среднее:

$$\hat{\mathbb{E}}[n] = \frac{1}{T_{\text{obs}}} \int_{T_{\text{warm}}}^{T_{\text{max}}} n(t) dt$$

Средний занятый ресурс:

$$\hat{\mathbb{E}}[u] = \frac{1}{T_{\text{obs}}} \int_{T_{\text{warm}}}^{T_{\text{max}}} u(t) dt$$

Время пребывания T_{soj} принятой заявки совпадает с её временем обслуживания S и равно $\frac{W}{\sigma}$.

Для анализа чувствительности используется сравнение метрик между базовым и изменённым сценарием. Вероятности отказа оценивает абсолютное отклонение в процентных пунктах:

$$\Delta P_{\text{loss}}(s, s_0) = 100 \cdot \left(\hat{P}_{\text{loss}}(s) - \hat{P}_{\text{loss}}(s_0) \right).$$

Для остальных метрик используется относительное отклонение:

$$\delta_m(s, s_0) = 100 \cdot \left(\frac{\hat{m}(s)}{\hat{m}(s_0)} - 1 \right).$$

Базовыми сценариями, относительно которых проверяется смещение результата является детерминированное обслуживание workload и пуассо-

новский входящий поток заявок.

Пусть для фиксированного сценария s и метрики m выполнено R_{rep} независимых репликаций. Тогда формируется выборка

$$Y_{s,m}^{(1)}, Y_{s,m}^{(2)}, \dots, Y_{s,m}^{(R_{\text{rep}})}.$$

Точечная оценка метрики вычисляется как выборочное среднее:

$$\bar{Y}_{s,m} = \frac{1}{R_{\text{rep}}} \sum_{r=1}^{R_{\text{rep}}} Y_{s,m}^{(r)}.$$

Выборочная дисперсия равна

$$S_{s,m}^2 = \frac{1}{R_{\text{rep}} - 1} \sum_{r=1}^{R_{\text{rep}}} \left(Y_{s,m}^{(r)} - \bar{Y}_{s,m} \right)^2.$$

Стандартная ошибка среднего:

$$\text{SE}_{s,m} = \frac{S_{s,m}}{\sqrt{R_{\text{rep}}}}.$$

Для оценки статистической надёжности результатов используются доверительные интервалы вида:

$$\bar{Y}_{s,m} \pm t_{1-\alpha/2, R_{\text{rep}}-1} \cdot \text{SE}_{s,m},$$

где $t_{1-\alpha/2, R_{\text{rep}}-1}$ --- квантиль распределения Стьюдента. В работе используется уровень доверия 95%.

В рамках работы оценивается абсолютный и относительный сдвиг следующих метрик: вероятности отказа, пропускной способности, среднее число заявок в системе, средний занятый ресурс, среднее время обслуживания и пребывания, декомпозиция отказов.

2.3 Алгоритм имитационного моделирования

Для выбранной постановки задачи и удобства компьютерной имитации выбрано моделирование методом Монте-Карло, так как в $GI/G/N/N/R$ си-

стеме каждая репликация является независимой реализацией одного и того же стохастического эксперимента.

Статистические характеристики модели оцениваются за время прогона $T_{\max}$, из которого исключается время разогрева T_{warm} . Таким образом, интервал наблюдения имеет длину

$$T_{\text{obs}} = T_{\max} - T_{\text{warm}}.$$

Время разогрева необходимо для уменьшения влияния начального состояния системы на стационарные оценки.

В рамках метода Монте-Карло выполняется серия из R_{rep} независимых репликаций, каждая из которых является одной полной реализацией эксперимента. При фиксированном сценарии s и выбранной целевой метрике m формируется выборка независимых значений

$$Y_{s,m}^{(1)}, Y_{s,m}^{(2)}, \dots, Y_{s,m}^{(R_{\text{rep}})}.$$

Один сценарий задаётся набором параметров

$$s = (a, \omega, \lambda, \sigma, N, K, R, F_D),$$

где a --- тип входящего потока, ω --- распределение объёма работы заявки, λ --- средняя интенсивность поступления, σ --- скорость обслуживания, N --- число серверов, K --- вместимость системы по числу заявок, R --- общий объём ресурса, F_D --- распределение ресурсного требования. В рассматриваемой loss-системе без очереди выполняется $K = N$.

В начале каждой репликации система находится в пустом состоянии:

$$n(0) = 0, \quad u(0) = 0,$$

где $n(t)$ --- число заявок в системе, $u(t)$ --- занятый ресурс в момент времени t .

Входящий поток задаётся последовательностью межприходных интервалов

$$A_1, A_2, \dots$$

с распределением, соответствующим выбранному типу arrival-процесса. Моменты поступления заявок определяются рекуррентно:

$$t_i = t_{i-1} + A_i.$$

Для каждой поступающей заявки генерируются ресурсное требование

$$D_i \sim F_D$$

и объём работы

$$W_i \sim F_W.$$

Фактическое время обслуживания определяется формулой

$$S_i = \frac{W_i}{\sigma}.$$

Имитация является дискретно-событийной. В каждый момент времени выбирается ближайшее событие: поступление новой заявки или завершение обслуживания одной из уже принятых заявок. Если множество активных заявок обозначить через $\mathcal{I}(t)$, то занятый ресурс имеет вид

$$u(t) = \sum_{i \in \mathcal{I}(t)} D_i.$$

При поступлении заявки в момент t_i проверяются ограничения системы:

$$n(t_i-) < K, \quad u(t_i-) + D_i \leq R.$$

Если оба условия выполнены, заявка принимается:

$$n(t_i+) = n(t_i-) + 1, \quad u(t_i+) = u(t_i-) + D_i.$$

Для принятой заявки планируется момент завершения обслуживания:

$$c_i = t_i + S_i.$$

Если хотя бы одно из ограничений нарушено, заявка теряется. В этом случае состояние системы не меняется, но увеличивается счётчик отказов.

Отказы дополнительно классифицируются по причине: превышение вместимости K , отсутствие доступного сервера N или недостаток ресурса R . В текущей loss-постановке $K = N$, однако отдельный учёт причин отказа сохраняется для диагностики.

При завершении обслуживания в момент c_i заявка покидает систему и освобождает один сервер и занятый ресурс:

$$n(c_i+) = n(c_i-) - 1, \quad u(c_i+) = u(c_i-) - D_i.$$

Статистика собирается только на интервале

$$[T_{\text{warm}}, T_{\text{max}}].$$

Если событие происходит до T_{warm} , оно влияет на состояние системы, но не входит в накопление статистики. Это позволяет использовать начальный участок траектории только для выхода системы из пустого состояния.

Между двумя соседними событиями значения $n(t)$ и $u(t)$ постоянны. Поэтому временные средние вычисляются как суммы площадей по межсобытийным интервалам:

$$\widehat{\mathbb{E}}[n] = \frac{1}{T_{\text{obs}}} \sum_j n_j \Delta t_j,$$

$$\widehat{\mathbb{E}}[u] = \frac{1}{T_{\text{obs}}} \sum_j u_j \Delta t_j,$$

где Δt_j --- длина очередного интервала между событиями после учёта разогрева, n_j и u_j --- значения состояния на этом интервале.

Для оценки стационарного распределения числа заявок в системе накапливается суммарное время пребывания в каждом состоянии:

$$\widehat{\pi}(k) = \frac{T_k}{T_{\text{obs}}},$$

где T_k --- суммарное время, в течение которого после периода разогрева в системе находилось k заявок. Тогда среднее число заявок может быть вы-

числено как

$$\hat{\mathbb{E}}[n] = \sum_{k=0}^K k \hat{\pi}(k).$$

Вероятность отказа оценивается как доля потерянных заявок:

$$\hat{P}_{\text{loss}} = \frac{N_{\text{rej}}}{N_{\text{arr}}},$$

где N_{arr} --- число попыток поступления, N_{rej} --- число отказов на интервале наблюдения.

Пропускная способность системы оценивается как число завершённых обслуживаний в единицу времени:

$$\hat{\theta} = \frac{N_{\text{completed}}}{T_{\text{obs}}}.$$

Для достаточно длинного интервала наблюдения в loss-системе также выполняется приближённая связь

$$\hat{\theta} \approx \lambda(1 - \hat{P}_{\text{loss}}),$$

так как доля принятых заявок равна $1 - \hat{P}_{\text{loss}}$.

Средний занятый ресурс вычисляется через накопленное ресурсное время:

$$\hat{\mathbb{E}}[u] = \frac{\text{resource_time}}{T_{\text{obs}}}.$$

Среднее время обслуживания и среднее время пребывания считаются по завершённым заявкам:

$$\hat{\mathbb{E}}[S] = \frac{1}{N_{\text{completed}}} \sum_{i=1}^{N_{\text{completed}}} S_i,$$

$$\hat{\mathbb{E}}[T_{\text{soj}}] = \frac{1}{N_{\text{completed}}} \sum_{i=1}^{N_{\text{completed}}} T_{\text{soj},i}.$$

В рассматриваемой loss-системе без очереди заявка не ожидает начала об-

служивания, поэтому для принятой заявки

$$T_{\text{soj},i} = S_i.$$

Обе величины сохраняются отдельно, так как в более общей системе с очередью они уже не совпадают.

После выполнения всех репликаций для каждого сценария s получается выборка значений каждой метрики:

$$Y_{s,m}^{(1)}, Y_{s,m}^{(2)}, \dots, Y_{s,m}^{(R_{\text{rep}})}.$$

Точечная оценка метрики равна выборочному среднему:

$$\bar{Y}_{s,m} = \frac{1}{R_{\text{rep}}} \sum_{r=1}^{R_{\text{rep}}} Y_{s,m}^{(r)}.$$

Выборочное стандартное отклонение определяется как

$$S_{s,m} = \sqrt{\frac{1}{R_{\text{rep}} - 1} \sum_{r=1}^{R_{\text{rep}}} \left(Y_{s,m}^{(r)} - \bar{Y}_{s,m} \right)^2}.$$

Стандартная ошибка среднего:

$$\text{SE}_{s,m} = \frac{S_{s,m}}{\sqrt{R_{\text{rep}}}}.$$

Для оценки статистической неопределённости строится доверительный интервал:

$$\bar{Y}_{s,m} \pm z_{1-\alpha/2} \text{SE}_{s,m},$$

где $z_{1-\alpha/2}$ --- квантиль стандартного нормального распределения. В работе используется уровень доверия 95%.

Шум Монте-Карло проявляется в разбросе значений $Y_{s,m}^{(r)}$ между независимыми репликациями. Если различие между двумя сценариями меньше или сопоставимо со стандартной ошибкой, оно не интерпретируется как устойчивый эффект чувствительности. Если же смещение между сценариями существенно превышает внутрисценарный разброс, то оно рассматривается как

значимое влияние изменяемого фактора.

Для сравнения двух сценариев s_1 и s_0 по метрике m используется абсолютное смещение

$$\Delta_m(s_1, s_0) = \bar{Y}_{s_1, m} - \bar{Y}_{s_0, m}.$$

Для вероятности отказа такое смещение удобно выражать в процентных пунктах:

$$\Delta P_{\text{loss}}(s_1, s_0) = 100 \cdot (\bar{Y}_{s_1, P_{\text{loss}}} - \bar{Y}_{s_0, P_{\text{loss}}}).$$

Для положительных метрик, таких как пропускная способность или средний занятый ресурс, дополнительно используется относительное смещение:

$$\delta_m(s_1, s_0) = 100 \cdot \left(\frac{\bar{Y}_{s_1, m}}{\bar{Y}_{s_0, m}} - 1 \right).$$

Таким образом, имитационный алгоритм состоит из трёх уровней. На нижнем уровне выполняется дискретно-событийная симуляция одной репликации. На среднем уровне для фиксированного сценария усредняются независимые репликации. На верхнем уровне сравниваются разные сценарии, отличающиеся типом входящего потока, распределением workload и уровнем нагрузки.

Для выбранной постановки задачи и удобства компьютерной имитации выбранно моделирование Монте-Карло, так как в $GI/G/N/N/R$ системе каждая репликация является независимой реализацией одного и того же стохастического эксперимента.

Статистические характеристики модели оцениваются за время прогона T_{max} из которого вычитается время разогрева T_{warm} ; таким образом получаем время наблюдения $T_{\text{obs}} = T_{\text{max}} - T_{\text{warm}}$. Время разогрева необходимо, чтобы нивелировать эффект начального состояния на статистику.

В рамках метода Монте-Карло выполняется серия из R_{rep} независимых репликаций (прогонов), каждая из которых является одной полной реализацией эксперимента. При фиксированном сценарии s и выбранной целевой метрике m формируется выборка независимых значений $Y_{s, m}^{(1)}, Y_{s, m}^{(2)}, \dots, Y_{s, m}^{(R_{\text{rep}})}$.

На основе полученной выборки далее вычисляются точечные интервальные статистические оценки

События бывают двух типов: поступление новой заявки и завершение обслуживания принятой заявки.

При поступлении заявки генерируются ресурсное требование D_i и workload W_i . Время обслуживания определяется как

$$S_i = \frac{W_i}{\sigma}.$$

Заявка принимается, если одновременно выполнены ограничения

$$n(t_i-) < N, \quad u(t_i-) + D_i \leq R.$$

Если хотя бы одно ограничение нарушено, заявка теряется. При принятии заявки увеличиваются счётчики принятых заявок, число занятых серверов и занятый ресурс:

$$n(t_i+) = n(t_i-) + 1, \quad u(t_i+) = u(t_i-) + D_i.$$

Также планируется момент завершения обслуживания:

$$c_i = t_i + S_i.$$

При завершении обслуживания заявка покидает систему, освобождая один сервер и занятый ресурс:

$$n(c_i+) = n(c_i-) - 1, \quad u(c_i+) = u(c_i-) - D_i.$$

Статистика собирается только на интервале после разогрева:

$$[T_{\text{warm}}, T_{\text{max}}].$$

Так как между соседними событиями состояние системы постоянно, временные средние вычисляются через накопление площадей:

$$\widehat{\mathbb{E}}[n] = \frac{1}{T_{\text{obs}}} \sum_j n_j \Delta t_j,$$

$$\widehat{\mathbb{E}}[u] = \frac{1}{T_{\text{obs}}} \sum_j u_j \Delta t_j.$$

Аналогично для оценки стационарного распределения числа заявок накапливается время пребывания системы в каждом состоянии:

$$\hat{\pi}(k) = \frac{T_k}{T_{\text{obs}}},$$

где T_k --- суммарное время, в течение которого после периода разогрева в системе находилось k заявок.

$$\hat{P}_{\text{loss}} = \frac{N_{\text{rej}}}{N_{\text{arr}}},$$

$$\hat{\theta} = \frac{N_{\text{completed}}}{T_{\text{obs}}},$$

$$\widehat{\mathbb{E}}[u] = \frac{\text{resource_time}}{T_{\text{obs}}},$$

$$\widehat{\mathbb{E}}[n] = \sum_{k=0}^K k \hat{\pi}(k).$$

Среднее время обслуживания и среднее время пребывания считаются по завершенным заявкам:

$$\widehat{\mathbb{E}}[S] = \frac{1}{N_{\text{completed}}} \sum_{i=1}^{N_{\text{completed}}} S_i,$$

$$\widehat{\mathbb{E}}[T_{\text{soj}}] = \frac{1}{N_{\text{completed}}} \sum_{i=1}^{N_{\text{completed}}} T_{\text{soj},i}.$$

В рассматриваемой loss-системе без очереди выполняется $T_{\text{soj},i} = S_i$, однако обе величины сохраняются отдельно для унификации формата результатов.

2.4 Семейства распределений обслуживания и входного потока

В ресурсной loss-СМО варьируются распределение межприходных интервалов входящего потока и распределение объёма работы заявки, все распределения внутри одного семейства нормируются по математическому ожи-

данию.

Пусть A --- случайный интервал между соседними поступлениями. Для всех входящих потоков выполняется условие

$$\mathbb{E}[A] = \frac{1}{\lambda}.$$

Вариативность межприходных интервалов характеризуется квадратом коэффициента вариации

$$c_A^2 = \frac{\text{Var}(A)}{\mathbb{E}[A]^2}.$$

Пуассоновский входящий поток задаётся экспоненциальным распределением межприходных интервалов:

$$A \sim \text{Exp}(\lambda), \quad f_A(t) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Для него

$$c_A^2 = 1.$$

Этот поток используется как базовый случай, поскольку он обладает марковским свойством и соответствует классической постановке $M/G/N/N/R$.

Регулярные входящие потоки моделируются распределением Эрланга порядка k :

$$A \sim \text{Erlang}(k, k\lambda),$$
$$f_A(t) = \frac{(k\lambda)^k t^{k-1} e^{-k\lambda t}}{(k-1)!}, \quad t \geq 0.$$

При такой параметризации сохраняется среднее значение:

$$\mathbb{E}[A] = \frac{1}{\lambda},$$

а вариативность равна

$$c_A^2 = \frac{1}{k}.$$

В работе используются $k = 2$ и $k = 4$. Эти потоки задают более равномерное поступление заявок по сравнению с пуассоновским потоком.

Нерегулярный входящий поток моделируется гиперэкспоненциальным

распределением второго порядка:

$$A \sim \begin{cases} \text{Exp}(\mu_1), & \text{с вероятностью } p, \\ \text{Exp}(\mu_2), & \text{с вероятностью } 1 - p. \end{cases}$$

Его плотность имеет вид

$$f_A(t) = p\mu_1 e^{-\mu_1 t} + (1 - p)\mu_2 e^{-\mu_2 t}.$$

Параметры μ_1 , μ_2 и p выбираются так, чтобы выполнялось условие

$$\mathbb{E}[A] = \frac{p}{\mu_1} + \frac{1 - p}{\mu_2} = \frac{1}{\lambda}.$$

Для гиперэкспоненциального распределения характерно

$$c_A^2 > 1.$$

Поэтому такой входящий поток используется для моделирования bursty-нагрузки: интервалы между заявками чередуют короткие плотные участки и более длинные паузы.

Второй варьируемый механизм --- распределение объёма работы заявки. Пусть W --- случайный объём работы, а фактическое время обслуживания равно

$$S = \frac{W}{\sigma}.$$

Во всех сценариях распределения workload нормируются так, что

$$\mathbb{E}[W] = 1, \quad \mathbb{E}[S] = \frac{1}{\sigma}.$$

Следовательно, сравнение workload-семейств проводится при одинаковом среднем времени обслуживания, но при разной вариативности:

$$c_W^2 = \frac{\text{Var}(W)}{\mathbb{E}[W]^2}.$$

Детерминированный workload задаётся как

$$W \equiv 1, \quad c_W^2 = 0.$$

Он соответствует полностью предсказуемому времени обслуживания.

Экспоненциальный workload задаётся распределением

$$W \sim \text{Exp}(1), \quad c_W^2 = 1.$$

Этот случай используется как классический марковский базис по обслуживанию.

Слабовариативный workload моделируется распределением Эрланга:

$$W \sim \text{Erlang}(k, k),$$

где в экспериментах используется $k = 4$. Тогда

$$\mathbb{E}[W] = 1, \quad c_W^2 = \frac{1}{4}.$$

Высоковариативный workload задаётся гиперэкспоненциальным распределением:

$$W \sim \begin{cases} \text{Exp}(\nu_1), & \text{с вероятностью } q, \\ \text{Exp}(\nu_2), & \text{с вероятностью } 1 - q. \end{cases}$$

Параметры выбираются из условия

$$\frac{q}{\nu_1} + \frac{1 - q}{\nu_2} = 1.$$

Такое распределение имеет $c_W^2 > 1$ и моделирует наличие коротких задач вместе с редкими длительными заявками.

Таким образом, в работе сравниваются распределения с одинаковыми первыми моментами, но с различными коэффициентами вариации. Это позволяет отдельно исследовать влияние формы входящего потока и распределения workload на характеристики ресурсной системы.

2.5 Структура программного комплекса и стадии эксперимента

Учитывая специфику имитируемой системы $GI/G/N/N/R$, каждая репликация может быть рассмотрена как независимый процесс, отсутствует буффер, т.е. нет необходимости хранить память об объектах в системе и отсутствует зависимость от состояния системы, было принято решение проводить вычислительный используя CUDA ядра видеокарты, каждое из которых может запускать 1 репликацию параллельно. Программный комплекс состоит из Python+Rust пайплайна, где первый валидирует и подает в систему значения параметров системы, отрисовывает графики в конце, а второй используется для производительности на тяжелых вычислениях.

Подготовка: `values.py` $\rightarrow$ `experiment_values.json`

Вычисления и анализ: `cargo run -- full` $\rightarrow$ `suite_result.json`

Визуализация результатов: $\rightarrow$ `plots.py`

Весь пайлайн запускается при помощи `launcher.py`, который организует порядок активации отдельных частей и передает нужную конфигурацию запуска cargo. Первый файл в цепочке - `values.py`, который задает исходную конфигурацию серии.

Таблица 2.2: Базовые параметры конфигурации вычислительного эксперимента

Группа	Параметр	Описание / Значение
Эксперимент	REPLICATIONS	Число независимых повторов
	MAX_TIME	Общее время моделирования в репликации
	WARMUP_TIME	Длина периода разогрева системы
Система	SERVERS_N	Количество обслуживающих каналов (серверов)
	TOTAL_R	Суммарный доступный ресурс системы
Нагрузка	ARR_LEVELS	Уровни интенсивности λ
	SIGMA_LEVELS	Скорость обслуживания σ
Распределения	WORKLOAD	Выбранные семейства распределений
	ARRIVAL	Выбранные семейства распределений

Во время запуска `values_validation.py` проверяет значения на осмысленность и соответствие условиям эксперимента, после чего `export_value` создает JSON-конфигурацию, который затем используется вычислительным модулем.

Rust пайплайн передает значения из файла `experiment_values.json` в `ExperimentConfig`. Затем модуль `scenario_grid.rs` строит сетку сценариев. Каждый сценарий является одной точкой в пространстве параметров:

$$s = (a, \omega, \lambda, \sigma, N, R, F_D),$$

где a --- тип входящего потока, ω --- распределение workload, λ --- средняя интенсивность поступления, σ --- скорость обслуживания, N --- число серверов, R --- общий ресурс, F_D --- распределение требования ресурса.

Пусть A --- множество типов входящего потока, Ω --- множество распределений workload, Λ --- набор уровней λ , Σ --- набор уровней σ . Тогда в зависимости от выбранного режима строятся разные декартовы произведения параметров:

$$\begin{aligned} \text{base:} & \quad \Lambda \times \Sigma, \\ \text{workload-sensitivity:} & \quad \Omega \times \Lambda \times \Sigma, \\ \text{arrival-sensitivity:} & \quad A \times \Lambda \times \Sigma, \\ \text{combined-sensitivity:} & \quad \Omega \times A \times \Lambda \times \Sigma, \end{aligned}$$

Для всех сценариев формируется `ScenarioSpec`. В нём хранится имя сценария, технический ключ, численная характеристика входящего потока и workload, параметры системы и распределение ресурса. После построения сетки модуль `experiments.rs` разделяет сценарии в список независимых прогонов.

Один CUDA thread (поток) выполняет 1 репликацию одного сценария, например при 3 значениях λ , 4 видах распределения workload и 4 видах распределения входящего потока заявок мы получаем сетку из 48 потоков - N_{sc} . Если задать число репликаций, например 20, то общее число потоков будет $48 \cdot 20 = 960$. Все они запускаются параллельно, каждый на отдельном CUDA ядре - $N_{runs} = N_{sc} \cdot R_{rep}$. Это позволят получить большой прирост скорости запуска одного эксперимента в текущей постановке, так как даже

непромышленные видеокарты позволят запустить эксперимент с группами параметров, который бы занял намного дольше на непромышленном процессоре. Однако, стоит учитывать, что даже один поток, превышающий число ядер видеокарты, удвоит время выполнения. Также сужается постановка задачи до $GI/G/N/N/R$, процессор для этого универсален.

Вычислительный backend получает список `RunRequest`, группирует батчи и передает в CUDA-ядро. Массив параметров содержит: $\lambda, \sigma, T_{\max}, T_{\text{warm}}, N, K$, а также численные коды распределений `arrival` и `workload`, параметры гиперэкспоненциальных распределений, массив значений ресурса D и соответствующая функция распределения. Внутри происходит имитация дискретно-событийной loss-системы, которая хранит текущее число заявок $n(t)$, занятый ресурс $u(t)$, параметры активных заявок и моменты их завершения.

По завершении каждого прогона backend формирует `RunSummary`, в которой содержатся счётчики поступлений, принятых заявок, отказов, завершений, вероятность отказа $\hat{P}_{\text{loss}}$, $\hat{\theta}$, $\hat{\mathbb{E}}[u]$, $\hat{\mathbb{E}}[n]$, среднее время обслуживания $\hat{\mathbb{E}}[S]$ и среднее время пребывания $\hat{\mathbb{E}}[T_{\text{soj}}]$.

После завершения всех прогонов модуль `experiments.rs` группирует результаты по ключу сценария. Для каждого сценария получается выборка значений метрики по независимым репликациям:

$$Y_{s,m}^{(1)}, Y_{s,m}^{(2)}, \dots, Y_{s,m}^{(R_{\text{rep}})}.$$

Модуль `stats.rs` вычисляет выборочное среднее:

$$\bar{Y}_{s,m} = \frac{1}{R_{\text{rep}}} \sum_{r=1}^{R_{\text{rep}}} Y_{s,m}^{(r)},$$

выборочное стандартное отклонение:

$$S_{s,m} = \sqrt{\frac{1}{R_{\text{rep}} - 1} \sum_{r=1}^{R_{\text{rep}}} \left(Y_{s,m}^{(r)} - \bar{Y}_{s,m} \right)^2},$$

стандартную ошибку:

$$\text{SE}_{s,m} = \frac{S_{s,m}}{\sqrt{R_{\text{rep}}}},$$

и доверительный интервал:

$$\bar{Y}_{s,m} \pm z_{1-\alpha/2} \text{SE}_{s,m}.$$

Модуль `output.rs` получает на вход значения `ExperimentSuiteResult` а именно имя серии, время создания, уровень доверия и набор агрегированных по всем сценариям результатов, и сохраняет результаты в директорию вида `results/<timestamp>__<suite_name>`. В неё записываются:

- `suite_result.json` --- полный результат серии, включая статистику по сценариям и отдельным репликациям;
- `aggregated_summary.csv` --- плоская агрегированная таблица по сценариям;
- `metric_summaries.csv` --- таблица статистик по метрикам;
- `run_summaries.csv` --- результаты отдельных репликаций;
- `suite_summary.txt` --- текстовая сводка серии.

После сохранения результатов `plots.py` читает `suite_result.json`, преобразует вложенную структуру в таблицы сценариев и репликаций, после чего строит графики для анализа чувствительности. Файл `plots_reworked.py` создан для анализа комбинированного сценария.

Таким образом Python отвечает за параметры эксперимента и визуализацию, Rust --- за тяжелые вычисления, которые требуют строгой типизации параметров, построение сценариев, агрегацию и сохранение результатов, а GPU-backend --- за параллельное выполнение независимых репликаций по методу Монте-Карло.

2.6 Контроль корректности и статистической надёжности результатов

3 ВЫЧИСЛИТЕЛЬНЫЙ АНАЛИЗ ЧУВСТВИТЕЛЬНОСТИ РЕСУРСНОЙ СИСТЕМЫ

В данной главе представлены результаты вычислительных экспериментов по анализу чувствительности ресурсной системы массового обслуживания. Описываются выбранные параметры имитационной модели, сценарии изменения входящего потока и распределения времени обслуживания. Оценивается влияние распределения объёма работы заявки и типа входящего потока на вероятность отказа, пропускную способность, среднее число заявок в системе и средний занятый ресурс. Приводится интерпритация полученных результатов.

3.1 Параметры вычислительного эксперимента

Входные данные для имитации были подобраны таким образом, чтобы рассмотреть систему в различных состояниях; особый интерес представляют значения при которых система близка к критическим состояниям, так как здесь чувствительность проявляется наиболее четко. В текущей постановке задачи параметры системы зафиксированы следующим образом: сервера $N = 96$, верхняя граница ресурса $R = 590$, скорость обслуживания $\sigma = 1.2$, интенсивность входящего потока λ варьируется $\lambda = 90, 104, 116$ для низкого среднего и высокого уровня нагрузки соответственно.

Распределение случайного требования к ресурсу D представлено в таблице 3.1.

Таблица 3.1: Распределение случайного требования к ресурсу D

Значение (d_i)	2	4	8	12	16
Вероятность (p_i)	0.25	0.25	0.30	0.15	0.05

Среднее требование к ресурсу для одной заявки, в соответствии с распределением в таблице 3.1, составляет 6,5. При полной занятости серверов ($n = N$) суммарный требуемый ресурс составил бы $N \cdot \mathbb{E}[D] = 96 \cdot 6.5 = 624$ единицы, что превышает доступную емкость $R = 590$.

Время работы системы в ходе одной репликации задается дискретно-событийно и установлено на уровне $T_{max} = 50000$ условных единиц времени, и $T_{warm} = 5000$ время разогрева. При значениях интенсивности входящего потока $\lambda \in [70, 116]$, что обеспечивает обработку от $3,5 \times 10^6$ до $5,8 \times 10^6$ заявок в рамках одной репликации.

Для получения статистически достоверных оценок стационарных характеристик и подавления шума Монте-Карло, каждый сценарий моделировался серией из $R_{rep} = 40$ независимых репликаций с различными инициализирующими значениями генератора псевдослучайных чисел. Согласно ЦПТ $R_{rep} > 30$ достаточен для корректной аппроксимации средних целевых метрик нормальным законом и позволяет надежно рассчитывать 95%-ные интервалы.

3.2 Сценарии анализа чувствительности

Для оценки чувствительности показателей эффективности системы (вероятности отказа в обслуживании) к виду распределений были сформированы наборы случайных величин для интервалов поступления (A) и объемов работы (W), имеющие идентичные математические ожидания, но различные коэффициенты вариации C_v (табл. 3.2).

Таблица 3.2: Типы распределений для анализа чувствительности

Параметр	Варианты распределений			
Входящий поток (Arrival)	Poisson	$Erlang_2$	$Erlang_4$	$Hyperexp_2$
Время работы (Workload)	Deterministic	Exponential	$Erlang_4$	Hyperexp

3.2.1 Моделирование входящего потока (Arrival Process)

Распределение входящего потока заявок определяет временную структуру нагрузки на систему. Выбранные семейства распределений для интервалов между поступлениями A :

1. Пуассоновский поток, при котором интервалы распределены экспоненциально: $f(t) = \lambda e^{-\lambda t}$, где $C_v = 1$. Это базовое распределение входящего потока, обладающее марковостью, относительно которого в дальнейшем измеряются отклонения.

2. Регулярные потоки Erlang-2 и Erlang-4, использующее распределение Эрланга k -го порядка:

$$f(t) = \frac{(k\lambda)^k t^{k-1} e^{-k\lambda t}}{(k-1)!}$$

Для $Erlang_4$ коэффициент вариации $C_v = 0.5$. Эти сценарии моделируют входящий поток, где заявки поступают равномерно по сравнению с другими распределениями.

3. Пачечный поток (Hyperexp-2). Моделируется как смесь двух экспоненциальных распределений с $C_v > 1$:

$$f(t) = p\lambda_1 e^{-\lambda_1 t} + (1-p)\lambda_2 e^{-\lambda_2 t}.$$

Выбор данного распределения обусловлен необходимостью анализа всплесков (burstiness), когда заявки приходят плотными группами за короткие промежутки времени, что часто провоцирует отказы системы.

3.2.2 Моделирование времени обслуживания (Workload)

Выбор распределений для объема работы заявки W позволяет оценить разные семейства распределения времени работы к ранее описанным входящим потокам.

1. Детерминированное обслуживание описывает сценарий, где $C_v = 0$, а $W = \mathbb{E}[W]$ всегда; служит для оценки поведения системы в условиях идеальной предсказуемости.
2. Экспоненциальное обслуживание служит для проверки классических аналитических свойств системы (в частности, свойств типа $M/M/N/0$).
3. Erlang-4 имеет низкую вариативность и моделирует процессы обслуживания с устойчивым временем выполнения.
4. Обслуживание с "тяжелыми хвостами"; имеет высокий коэффициент вариации ($C_v \gg 1$). Этот сценарий имитирует наличие редких, но экстремально ресурсоемких задач. В условиях ограниченного ресурса они способны блокировать систему на длительное время, что должно приводить к росту вероятности отказа P_{loss} при стабильных входящих потоках.

Параметры распределений во всех сценариях подобраны так, чтобы математическое ожидание соответствовало заданному уровню нагрузки: $\mathbb{E}[W] = 1/\sigma = 0.833$.

3.3 Чувствительность к распределению объёма работы заявки

Основная цель данного раздела заключается в проверке гипотезы о сохранении свойства инвариантности в РСМО, что подтверждается на полученных данных: переход от экспоненциального распределения к детерминированному, распределению Эрланга или гиперэкспоненциальному закону при сохранении идентичного среднего значения $\mathbb{E}[W] = 1/\sigma$ не приводит к статистически значимым изменениям ключевых показателей эффективности.

На рисунке 3.1 представлены основные показатели системы в зависимости от интенсивности нагрузки для различных типов распределения обслуживания.




Рис. 3.1: Основные показатели эффективности системы при различных распределениях времени обслуживания

Анализ относительного смещения показателей относительно марковского базиса (Exponential), представленные в виде тепловой карты на рисунке 3.2, показывают, что девиации большинства метрик от не превышают долей процента.




Рис. 3.2: Относительное отклонение метрик от экспоненциального распределения обслуживания (delta heatmap)

Эффект от изменения формы распределения времени обслуживания сопоставим с уровнем статистического шума метода Монте-Карло, как видно из диаграммами размаха на рисунке 3.3.




Рис. 3.3: Диаграмма размаха вероятности потери для различных типов обслуживания ($\lambda = 116$)

При этом межквартильные размахи (ширина «ящиков»), отражающие дисперсию результатов между независимыми репликациями, полностью перекрывают друг друга.

На рисунке 3.4 показана оценка стационарного распределения числа заявок в системе $\pi(k)$ в логарифмическом масштабе.



Рис. 3.4: Оценка стационарного распределения вероятностей состояний $\pi(k)$ ($\lambda = 116$)

Кривые вероятностей состояний для детерминированного, экспоненциального, эрланговского и гиперэкспоненциального законов обслуживания полностью совпадают на всем диапазоне возможных состояний и не расходятся даже в области «хвостов».

Выводы по разделу

При марковском (пуассоновском) входящем потоке в исследуемой ресурсной системе чувствительность к закону распределения времени работы заявки практически отсутствует. Все зафиксированные расхождения превышают долей процента и полностью объясняются дисперсией метода Монте-Карло. Полученный результат согласуется с классическим свойством инвариантности стационарного распределения[sopin2018_insensitivity; sopin2019_ecms]

Таким образом, для данного режима работы подтверждена возможность использования простейших экспоненциальных аппроксимаций $M/M/N/R$ без потери точности моделирования [dudin2025_random_environment].

3.4 Чувствительность к типу входящего потока

В данном разделе анализируется влияние типа входящего потока на показатели эффективности ресурсной loss-системы. Рассматриваются следующие типы входящего потока:

$$a \in \{\text{Poisson}, \text{Erlang-2}, \text{Erlang-4}, \text{HyperExp-2}\}.$$

, при фиксированном детерменированном распределении времени работы.

Во всех сценариях данного раздела выполняется условие $\mathbb{E}[A] = \frac{1}{\lambda}$, где A --- случайный межприходный интервал. Базовым сценарием для сравнения выбран пуассоновский поток $a_0 = \text{Poisson}$.

На рисунке 3.5 представлены основные показатели эффективности системы при различных типах входящего потока и уровнях интенсивности λ .




Рис. 3.5: Основные показатели эффективности системы при различных типах входящего потока

При увеличении λ вероятность отказа возрастает; темп роста различается для разных распределений. Наименьшие значения вероятности отказа наблюдаются для регулярных эрланговских потоков, а наибольшие --- для гиперэкспоненциального потока.

На рисунке 3.6 отдельно показана вероятность отказа по уровням интенсивности λ .




Рис. 3.6: Вероятность отказа при различных типах входящего потока и уровнях λ

Чем больше λ тем более выраженным становится различие между различными распределениями входящего потока. Гиперэкспоненциальный поток даёт максимальную вероятность отказа, а поток Эрланга четвёртого порядка остаётся наиболее благоприятным.

Для проверки устойчивости полученных различий были построены диаграммы размаха по независимым репликациям. Ниже приведён разброс вероятности отказа при $\lambda = 116$.




Рис. 3.7: Разброс вероятности отказа по репликациям при $\lambda = 116$

Видно, что межсценарные различия значительно превышают внутри-сценарный разброс по репликациям. Наблюдаемая чувствительность к типу входящего потока не является следствием шума Монте-Карло. В отличие от результатов по распределению workload, здесь различия между сценариями статистически выражены.

На рисунке 3.8 показано исследование $\pi(k)$ при $\lambda = 116$.




Рис. 3.8: Стационарное распределение числа заявок в системе $\pi(k)$ при различных типах входящего потока ($\lambda = 116$)

Кривые на графике сильно варьируются, для регулярных потоков распределение смещенно в сторону больших значений k . При гиперэкспоненциальном потоке распределение $\pi(k)$ более пологое, но растет ближе к левому краю из-за редких приходов больших пачек заявок.

Дополнительно была построена оценка хвоста стационарного распределения числа заявок в системе 3.9.




Рис. 3.9: Хвост стационарного распределения числа заявок в системе при $\lambda = 116$

Хвостовое распределение подтверждает различие режимов заполнения системы. Для регулярных эрланговских потоков распределение держится на высоких (много заявок в системе) устойчивых значениях - загрузка равномерная. У гиперэкспоненциального входящего потока хвост убывает медленнее - высокая вероятность состояний с высокой занятостью системы, множество отказов по ресурсу R .

Выводы по разделу

Тип входящего потока является ключевым фактором чувствительности ресурсной loss-системы. При одинаковом λ различные распределения межприходных интервалов приводят к принципиально разной вероятности отказа, пропускной способности и средней занятости.

Регулярные потоки Эрланга уменьшают вероятность отказа, а гиперэкспоненциальный поток увеличивает вероятность отказа из-за локальных перегрузок.

3.5 Совместное влияние распределения обслуживания и входного потока

В данном разделе анализируется полный набор сценариев, в котором одновременно варьируются тип входящего потока a , распределение объёма работы заявки ω и интенсивность поступления λ .

Каждый сценарий можно записать в виде

$$s = (a, \omega, \lambda, \sigma, N, R, F_D),$$

где a --- тип входящего потока, ω --- тип распределения workload, λ --- средняя интенсивность поступления, σ --- скорость обслуживания, N --- число обслуживающих каналов, R --- общий объём ресурса, F_D --- распределение ресурсного требования заявки.

Базовым сценарием является детерминированный workload и пуассоновский входящим потоком $s_0(\lambda) = (\text{Poisson}, \text{Deterministic}, \lambda)$.

Для вероятности отказа совместное смещение относительно базового сценария измеряется в процентных пунктах:

$$\Delta p_{\text{loss}}(a, \omega, \lambda) = 100 \cdot (\hat{p}_{\text{loss}}(a, \omega, \lambda) - \hat{p}_{\text{loss}}(\text{Poisson}, \text{Deterministic}, \lambda)).$$

Для остальных метрик используется относительное отклонение:

$$\delta_m(a, \omega, \lambda) = 100 \cdot \left(\frac{\hat{m}(a, \omega, \lambda)}{\hat{m}(\text{Poisson}, \text{Deterministic}, \lambda)} - 1 \right).$$

То есть на графиках сравниваются именно отклонения от базового сценария при той же самой интенсивности λ . Например, на рисунке 3.10 представлена матрица значений вероятности отказа для всех сочетаний workload и arrival-процесса.




Рис. 3.10: Матрица workload × arrival для вероятности отказа

При пуассоновском входящем потоке P_{loss} практически не зависит от распределения workload, как было ранее установлено в 3.3. При $c_A^2 = 1$, изменение c_B^2 практически не меняет вероятность отказа. Например, при $\lambda = 116$ для всех четырёх workload расхождения вероятности отказа находятся на уровне 0.01 процентного пункта: 10.62%, 10.62%, 10.63%, 10.62%. Это подтверждает инвариантность РСМО относительно распределения времени обслуживания при пуассоновском входе.

При непуассоновских входящих потоках инвариантность по распределению workload нарушается, причём знак эффекта зависит от вариативности входящего потока. Для регулярных потоков Эрланга увеличение вариативности workload повышает вероятность отказа, а для гиперэкспоненциального входа, наоборот, снижает её; выполняется следующий порядок квадратов коэффициентов вариации:

$$c_A^2(\text{Erlang-4}) < c_A^2(\text{Erlang-2}) < c_A^2(\text{Poisson}) < c_A^2(\text{HyperExp}),$$

где

$$\begin{aligned} c_A^2(\text{Erlang-4}) &= 0.25, & c_A^2(\text{Erlang-2}) &= 0.5, \\ c_A^2(\text{Poisson}) &= 1, & c_A^2(\text{HyperExp}) &> 1. \end{aligned}$$

Для регулярных входящих потоков наблюдается наименьшая вероятность отказа, но чем выше вариативность workload, тем больше будет вероятность отказа. При $\lambda = 116$ и входящем потоке Erlang-4 значения вероятности

отказа соответствуют следующим workload:

$$\begin{aligned} \text{Deterministic} &= 7.65\% \rightarrow \text{Erlang-4} = 9.03\% \\ \rightarrow \text{Exponential} &= 9.28\% \rightarrow \text{Heavy-tail} = 9.71\%, \end{aligned}$$

Для Erlang-2:

$$8.81\% \rightarrow 9.60\% \rightarrow 9.75\% \rightarrow 10.02\%,$$

Абсолютный рост между детерминированным и heavy-tail workload составляет 2.06 процентного пункта для Erlang-4 и 1.21 для Erlang-2. Следовательно, для регулярного входа выполняется соотношение $\frac{\partial P_{\text{loss}}}{\partial c_B^2} > 0$. Регулярный поток лучше всего сочетается с регулярным обслуживанием.

Для гиперэкспоненциального входящего потока знак эффекта меняется. При $\lambda = 116$ вероятность отказа уменьшается при росте вариативности workload, выполняется обратная зависимость:

$$17.61\% \rightarrow 15.40\% \rightarrow 14.83\% \rightarrow 13.63\%.$$

Выполняется обратная зависимость $\frac{\partial P_{\text{loss}}}{\partial c_B^2} < 0$, так как гиперэкспоненциальный поток создаёт пачки поступлений и детерминированный workload долго выходит из перегрузок, а более вариативные режимы освобождают ресурс пачечно и снижают отказ.

Это же видно на условном смещении arrival относительно пуассоновского входа при фиксированном workload:

Смещение arrival относительно Пуассона при том же workload: Вероятность отказа | $\sigma=1.2$




Рис. 3.11: Относительное отклонение вероятности потери от пуассоновского базлайна при различных распределениях обслуживания

Для Erlang-потоков $\Delta_A P_{\text{loss}} < 0$, для гиперэкспоненциального входа $\Delta_A P_{\text{loss}} > 0$. При $\lambda = 116$ и детерминированном workload, где регуляризация входящего потока снижает вероятность отказа на 1.8-3.0 п.п., а bursty-вход увеличивает её почти на 7 п.п.: $\Delta_A P_{\text{loss}}(\text{Erlang-2}, \text{Erlang-4}, \text{HyperExp}) = -1.809, -2.970, +6.986$ соответственно.

Распределение workload само по себе не имеет универсального положительного или отрицательного влияния, его эффект определяется типом входящего потока.

Смещение workload относительно детерминированного при том же arrival: Вероятность отказа | $\sigma=1.2$




Рис. 3.12: Относительное отклонение вероятности потери от детерминированного обслуживания при различных входящих потоках

Поведение остальных метрик согласуется с формулой пропускной способности $\lambda(1 - P_{\text{loss}})$. При фиксированной λ рост вероятности отказа автоматически снижает throughput. Поэтому сценарии с Erlang arrival имеют большую пропускную способность, а сценарии с HyperExp arrival --- меньшую. Разница между Erlang-4 и HyperExp при $\lambda = 116$ составляет $107.1 - 95.6 = 11.5$ заявки на единицу времени или почти на 11%. Средний занятый ресурс ведёт себя аналогично.

Матрица workload $\times$ arrival: Пропускная способность | $\sigma=1.2$




Рис. 3.13: Тепловая карта пропускной способности системы при совместном варьировании распределений

Матрица workload × arrival: Средний занятый ресурс | $\sigma=1.2$




Рис. 3.14: Тепловая карта среднего занятого ресурса при совместном варьировании распределений

Структура отказов подтверждает, что главным ограничением в рассматриваемой постановке является ресурс R , а затем только число серверов N .

Структура отказов по workload × arrival | $\sigma=1.2$




Рис. 3.15: Структура отказов (доля блокировок по серверам и по ресурсу) при совместном варьировании распределений

Менее равномерный вход увеличивает оба типа отказов, но основной вклад даёт именно ограничение по ресурсу.

Выводы по разделу

Совместный эксперимент показывает, что чувствительность ресурсной loss-СМО связана с типом входящего потока. При одинаковом λ регулярные Erlang-потоки уменьшают вероятность отказа, а гиперэкспоненциальный поток существенно увеличивает её. Сгладить влияние bursty потоков позволяет менее однородное распределение времени работы. Для всех уровней нагрузки сохраняется порядок:

$$P_{\text{loss}}(\text{Erlang-4}) < P_{\text{loss}}(\text{Erlang-2}) < P_{\text{loss}}(\text{Poisson}) < P_{\text{loss}}(\text{HyperExp})$$

Для ресурсных loss-СМО необходимо учитывать прежде всего среднюю нагрузку, затем форму входящего потока и наконец её взаимодействие с распределением времени обслуживания.

3.6 Практическая интерпретация результатов и выводы

Вычислительные эксперименты проводились для ресурсной loss-СМО $GI/G/N/N/R$ при фиксированных параметрах $N = 96$, $R = 590$, $\sigma = 1.2$, $\mathbb{E}[W] = 1/\sigma = 0.833$. Интенсивность входящего потока принимала значения $\lambda \in \{90, 104, 116\}$. Распределение ресурсного требования D задавалось значениями 2, 4, 8, 12, 16 с вероятностями 0.25, 0.25, 0.30, 0.15, 0.05, поэтому $\mathbb{E}[D] = 6.5$. Каждый сценарий оценивался по 40 независимым репликациям.

Основным фактором чувствительности в рассматриваемой системе является тип входящего потока. Различные распределения A приводят к разнообразным значениям вероятности отказа, пропускной способности и средней занятости ресурса. Регулярные потоки Эрланга уменьшают вероятность отказа, а гиперэкспоненциальный поток, моделирующий всплески поступлений, существенно её увеличивает.

Вторым по значению фактором чувствительности является средняя интенсивность потока λ .

Распределение объёма работы заявки W при пуассоновском входящем потоке подтверждает свойство инвариантности системы. При непуассоновском входе инвариантность нарушается. Распределение времени обслуживания зависит от входящего потока заявок и может улучшить отказоустойчи-

вость: при равномерном входящем потоке выигрыш дает равномерное распределение workload, при крайне неравномерном входящем потоке burstly workload позволяет снизить потери. Лучшим сочетанием является Erlang-4 входящий поток и deterministic workload, худшим гиперэкспоненциальный входящий поток и deterministic workload.

Декомпозиция отказов показывает, что в выбранной конфигурации главным ограничивающим фактором является ресурс R .

ЗАКЛЮЧЕНИЕ

А ТАБЛИЦЫ ПАРАМЕТРОВ ВЫЧИСЛИТЕЛЬНОГО ЭКСПЕРИМЕНТА